

الإطار الأخلاقي الوطني للذكاء الاصطناعي

الصفحة 1 من 3 | كود المستند: doc_ar_03

المبدأ الأول: العدالة والإنصاف ومنع التحيز الخوارزمي

يجب تصميم نماذج الذكاء الاصطناعي وتدريبها لضمان عدم التمييز ضد الأفراد أو الفئات بناء على أي صفات غير موضوعية. تلتزم الجهات المطورة بإجراء اختبارات دورية للكشف عن التحيز الإحصائي في بيانات التدريب ومعالجتها قبل الإطلاق التجاري.

المبدأ الثاني: الشفافية والقابلية للتفسير الخوارزمي

يجب تمكين المستخدمين من فهم القرارات الصادرة عن أنظمة الذكاء الاصطناعي وتوضيح العوامل الرئيسية المؤثرة في النتيجة.

يتعين الإفصاح صراحة للمستخدمين عندما يتفاعلون مع نظام ذكاء اصطناعي محادثاتي أو وكيل افتراضي آلي.

الإطار الأخلاقي الوطني للذكاء الاصطناعي

الصفحة 2 من 3 | كود المستند: doc_ar_03

المبدأ الثالث: الأمان والموثوقية التقنية للنماذج

يجب أن تتمتع أنظمة الذكاء الاصطناعي بمرونة عالية ضد الهجمات العدائية مثل التسمم البياني والتلاعب بالمدخلات.

يلزم وضع خطط تشغيلية بديلة وتوفير إمكانية الإيقاف اليدوي الفوري في حال حدوث انحراف في سلوك النظام الآلي.

المبدأ الرابع: الخصوصية وحوكمة البيانات في أنظمة الذكاء الاصطناعي

يحظر استخدام البيانات الشخصية في تدريب نماذج الذكاء الاصطناعي دون وجود مسوغ نظامي وموافقة صريحة موثقة.

يجب تطبيق تقنيات إخفاء الهوية وتقليل جمع البيانات إلى الحد الأدنى الضروري لتحقيق الغرض التشغيلي فقط.

المبدأ الخامس: المساءلة والإشراف البشري الفعال

يظل المشغلون والمطورون مسؤولين نظاما وقانونا عن الآثار والقرارات المترتبة على عمل منظومة الذكاء الاصطناعي.

يجب ضمان وجود تدخل وإشراف بشري (Human-in-the-loop) في كافة القرارات الآلية التي تمس الحقوق المدنية والمالية للأفراد.

يحق للمتضرر من قرار صادر عن نظام ذكاء اصطناعي آلي بالكامل المطالبة بمراجعة بشرية للقرار والحصول على تسبيب مكتوب.